SompoRisk AI

v2.3.0 · Documentação Completa · Sprint 2

SEÇÃO 01

Visão Geral

A SompoRisk AI é uma solução baseada em Inteligência Artificial voltada à identificação e previsão de riscos operacionais em operações agrícolas. A arquitetura coleta dados climáticos históricos reais via API Open-Meteo, enriquece o dataset com variáveis operacionais simuladas, persiste os dados no Oracle Database, executa um pipeline completo de Machine Learning e disponibiliza os resultados num dashboard analítico construído em Streamlit.

Esta versão 2.3.0 representa a entrega completa do Sprint 2 do Challenge FIAP × Sompo Seguros, consolidando todos os módulos implementados e documentando a arquitetura final da solução.

SEÇÃO 02

Problema

Operações agrícolas frequentemente tomam decisões de forma reativa, percebendo falhas, atolamentos e acidentes somente após o evento ocorrer. Isso gera altos custos operacionais, sinistros evitáveis e interrupções não planejadas. Os principais fatores de risco são:

- — Chuva intensa associada a solo excessivamente úmido
- — Operação próxima a corpos d'água ou em terrenos inclinados
- — Excesso de velocidade em condições adversas de terreno
- — Manutenção inadequada ou atrasada dos equipamentos
- — Ausência de mecanismos preditivos para antecipação de cenários críticos

SEÇÃO 03

Objetivo

Criar uma plataforma inteligente capaz de transformar dados climáticos e operacionais em decisões preventivas, atendendo às três personas principais do projeto:

Persona	Necessidade	Entrega da Solução
Operador de Campo	Evitar acidentes e danos ao equipamento	Alertas preventivos baseados em ML

Gestor de Frota	Reduzir custos e priorizar manutenção	Ranking de risco por equipamento/cidade
Analista da Seguradora	Antecipar sinistros futuros	Análise preditiva com probabilidades

SEÇÃO 04

Arquitetura Geral

O pipeline completo da solução segue o fluxo abaixo, do dado bruto até o dashboard:

Módulo / Componente	Responsabilidade
Open-Meteo API	Fonte de dados climáticos históricos (temperatura, chuva, data)
api_clima.py	Coleta coordenadas e histórico climático por cidade
gerar_dataset.py	Gera dataset híbrido: dados reais + operacionais simulados
TB_RISCO_AGRICOLA	Oracle — armazena dados brutos com indicadores binários
pre_processamento.py	Limpeza, validação e padronização dos dados
TB_RISCO_AGRICOLA_TRATADO	Oracle — dados limpos e prontos para IA
preparar_features.py	Engenharia de features + criação da variável alvo
treinar_arvore.py	Treinamento da DecisionTreeClassifier (75/25 split)
arvore_decisao.pkl	Modelo serializado — artefato de treinamento
prever_risco.py	Previsão por cidade consultando Oracle em tempo real
gerar_explicacao_modelo.py	Gera resultados explicados baseados nas saídas do modelo
TB_PREVISAO_RISCO	Oracle — armazena previsões com probabilidades
Dashboard.py	Streamlit — visualização, ranking, mapa e alertas

Linhas em azul claro representam componentes de persistência (Oracle Database e modelo pkl).

SEÇÃO 05

Camada de Coleta — Open-Meteo

A coleta de dados climáticos é feita pela API pública Open-Meteo, sem necessidade de autenticação. O módulo api_clima.py centraliza toda a comunicação com a API.

Dados coletados

- — Temperatura média diária (°C)
- — Precipitação diária (mm)
- — Data da medição
- — Período: 01/01/2024 até a data atual

Cidades monitoradas (9 municípios de SP)

São Paulo · Campinas · Ribeirão Preto · Sorocaba · Piracicaba · Araraquara · São José dos Campos · Ribeirão Pires · Taquaritinga

SEÇÃO 06

Camada de Dados — Dataset Híbrido

O dataset combina dados climáticos reais com variáveis operacionais simuladas, totalizando milhares de registros desde 01/01/2024.

Variável	Origem	Descrição	Validação
temperatura	Real	Temperatura média diária (°C)	-10 a 60°C
chuva_mm	Real	Precipitação diária (mm)	0 a 300 mm
umidade_solo	Simulado	Umidade do solo (%)	0 a 100%
velocidade_kmh	Simulado	Velocidade do equipamento	0 a 100 km/h
proximidade_agua_m	Simulado	Distância de corpo d'água (m)	0 a 5000 m
inclinacao_graus	Simulado	Inclinação do terreno (°)	0 a 90°
tempo_uso_horas	Simulado	Horas de uso diário	0 a 24h
manutencao_dias	Simulado	Dias desde última manutenção	0 a 365 dias

SEÇÃO 07

Indicadores Operacionais Binários

Os indicadores binários são variáveis derivadas que sinalizam condições críticas de forma objetiva (0 = condição ausente, 1 = condição presente). São utilizados tanto no treinamento do modelo quanto na geração de explicações para o usuário final.

Indicador	Regra de Ativação	Interpretação de Risco
INDICADOR_CHUVA_ALTA	`chuva_mm > 30`	Risco de atolamento e perda de tração
INDICADOR_SOLO_UMIDO	`umidade_solo > 70%`	Solo com baixa capacidade de suporte
INDICADOR_VELOCIDADE_ALTA	`velocidade_kmh > 18`	Redução do tempo de reação a obstáculos
INDICADOR_PERTO_AGUA	`proximidade_agua_m < 100`	Risco de encharcamento e instabilidade
INDICADOR_INCLINACAO_ALTA	`inclinacao_graus > 15°`	Instabilidade e risco de tombamento
INDICADOR_MANUTENCAO_ATRASADA	`manutencao_dias > 90`	Maior probabilidade de falha mecânica

A variável alvo ocorrencia_risco é criada probabilisticamente a partir da soma desses indicadores: 4+ ativos = 75% de chance, 2-3 ativos = 35% de chance, 0-1 ativo = 8% de chance. Essa abordagem torna o modelo mais realista, pois nem toda condição perigosa resulta em incidente.

SEÇÃO 08

Banco de Dados — Oracle Database

O projeto utiliza Oracle Database para persistência em todas as etapas do pipeline. As credenciais são carregadas via arquivo .env (nunca versionado).

Tabela	Conteúdo	Origem / Destino
TB_RISCO_AGRICOLA	Dados brutos: climáticos reais + operacionais simulados + indicadores binários	Gerado por gerar_dataset.py
TB_RISCO_AGRICOLA_TRATADO	Dados limpos, validados e padronizados para uso em ML	Gerado por pre_processamento.py
TB_PREVISAO_RISCO	Previsões geradas pelo modelo: cidade, data, classificação, probabilidades	Gerado por prever_risco.py

SEÇÃO 09

Pré-processamento

Executado por pre_processamento.py. Transforma TB_RISCO_AGRICOLA em TB_RISCO_AGRICOLA_TRATADO aplicando as seguintes etapas:

- — Remoção de duplicidades e registros inválidos
- — Conversão e padronização de tipos (pd.to_numeric, pd.to_datetime)
- — Validação de faixas numéricas (temperatura, chuva, umidade, velocidade, etc.)
- — Padronização de campos textuais (cidade, datas)
- — Preparação da base oficial para treinamento dos modelos

SEÇÃO 10

Machine Learning — Pipeline Completo

10.1 — preparar_features.py

Carrega TB_RISCO_AGRICOLA_TRATADO e prepara os dados para treinamento: decomposição da data em atributos temporais (ano, mes, dia, dia_semana), seleção das 20 features finais e criação da variável alvo ocorrencia_risco com lógica probabilística.

10.2 — treinar_arvore.py

Treina o modelo DecisionTreeClassifier com os seguintes parâmetros:

Parâmetro	Valor	Justificativa
criterion	`gini`	Medida de impureza padrão para classificação binária
max_depth	`5`	Controla overfitting mantendo interpretabilidade
random_state	`42`	Garante reprodutibilidade dos experimentos
test_size	`0.25`	25% reservado para avaliação do modelo
stratify	`y`	Mantém proporção de classes em treino e teste

Métricas avaliadas: Accuracy, Precision, Recall, F1-Score e Matriz de Confusão. Artefatos gerados: models/arvore_decisao.pkl e models/features.pkl.

10.3 — Features utilizadas (20 variáveis)

Grupo	Features
Climáticas	temperatura, chuva_mm
Operacionais	umidade_solo, velocidade_kmh, proximidade_agua_m, inclinacao_graus, tempo_uso_horas, manutencao_dias
Indicadores	indicador_chuva_alta, indicador_solo_umido, indicador_velocidade_alta, indicador_perto_agua, indicador_inclinacao_alta, indicador_manutencao_atrasada
Temporais	ano, mes, dia, dia_semana

SEÇÃO 11

Previsão e Saídas do Sistema

O módulo prever_risco.py recebe uma cidade, consulta o último registro disponível no Oracle e retorna a previsão completa:


```
{ "cidade": "São Paulo", "data_medicao": "2026-06-02", "risco_previsto": 1,
"classificacao": "alto", "probabilidades": { "0": 0.4731, "1": 0.5269 } }
```


O módulo gerar_explicacao_modelo.py complementa a previsão com linguagem natural, identificando quais indicadores estavam ativos e traduzindo-os em explicações operacionais e recomendações preventivas (ex.: 'Realizar manutenção preventiva', 'Evitar operação em áreas úmidas'). Isso aumenta a confiança do usuário e apoia auditorias.

SEÇÃO 12

Dashboard — Streamlit

Implementado em Streamlit com integração direta ao Oracle Database, o dashboard oferece:

- — Monitoramento centralizado de equipamentos por cidade e período
- — Visualização do risco previsto (baixo / alto) com probabilidades
- — Ranking de equipamentos com maior probabilidade de incidente
- — Ranking de cidades por nível de criticidade
- — Mapa geográfico de riscos por município
- — Alarmes críticos automáticos para apoio à decisão
- — Indicadores operacionais e ambientais em tempo real
- — Filtros dinâmicos por período, cidade e equipamento

SEÇÃO 13

Stack Tecnológica

Camada	Tecnologias
Linguagem principal	Python 3.x
Dados e processamento	Pandas, NumPy, python-dotenv
Machine Learning	scikit-learn (DecisionTreeClassifier), joblib
Banco de Dados	Oracle Database via oracledb
API climática	Open-Meteo (pública, sem autenticação)
Visualização	Streamlit, Plotly
Comunicação HTTP	requests

SEÇÃO 14

Diferenciais da Solução

— Dados climáticos históricos reais (Open-Meteo) — sem fabricação de dados climáticos
— Oracle Database para persistência rastreável em todas as etapas
— Machine Learning interpretável com Árvore de Decisão e explicabilidade em linguagem natural
— Arquitetura modular — cada script tem responsabilidade única e bem definida
— Dashboard analítico integrado diretamente ao banco de dados
— Persistência das previsões com probabilidades em TB_PREVISAO_RISCO
— Variável alvo probabilística que simula comportamento mais próximo da realidade
— Documentação técnica completa e estruturada em múltiplos níveis

SEÇÃO 15

Roadmap do Projeto

Módulo	Status	Versão
Arquitetura e escopo	✓ **Concluído**	v1.0.0
Integração Open-Meteo	✓ **Concluído**	v1.0.0
Geração do dataset híbrido	✓ **Concluído**	v2.1.0
Oracle Database (3 tabelas)	✓ **Concluído**	v2.1.0
Pré-processamento estruturado	✓ **Concluído**	v2.1.0
Machine Learning — Árvore de Decisão	✓ **Concluído**	v2.1.0
Previsão de risco por cidade	✓ **Concluído**	v2.2.0
TB_PREVISAO_RISCO — persistência	✓ **Concluído**	v2.2.0
Dashboard Streamlit	✓ **Concluído**	v2.2.0
Explicabilidade do modelo (IA)	✓ **Concluído**	v2.3.0

Documentação técnica completa	✓ **Concluído**	v2.3.0

API REST (FastAPI/Flask)	■ **Em desenvolvimento**	v3.0.0
Integração Gemini AI	■ **Em desenvolvimento**	v3.0.0
Alertas por e-mail	■ **Em desenvolvimento**	v3.0.0
Random Forest / XGBoost	■ **Futuro**	v4.0.0
Dados reais de sinistros	■ **Futuro**	v4.0.0